Cynthia Cristal Quijas Flores - A01655996

```
• Alejandro Sanchez Flores - A01662783

    Carlos Adrian Palmieri Álvarez - A01635776

    Dabria Camila Carrillo Meneses - A01656716

 In [6]: import numpy as np
         import tensorflow as tf
         import matplotlib.pyplot as plt
         from tensorflow.keras.preprocessing.image import ImageDataGenerator
         from tensorflow.keras.applications import ResNet50
         from tensorflow.keras import layers, models
         from tensorflow.keras.optimizers import Adam
In [10]: # DEFINIMOS LAS RUTAS DE NUESTRO DATASET PERSONALIZADO
         train_dir = r'./Imagenes_Class/train/'
         val_dir = r'./Imagenes_Class/val/'
In [11]: # PROCESAMOS LAS IMAGENES Y GENERAMOS LOS LOTES
         train_datagen = ImageDataGenerator(rescale=1./255, horizontal_flip=True, rotation_range=20, zoom_range=0.2)
         val_datagen = ImageDataGenerator(rescale=1./255)
         train_generator = train_datagen.flow_from_directory(train_dir, target_size=(224, 224), batch_size=32, class_mode='categorical')
         val_generator = val_datagen.flow_from_directory(val_dir, target_size=(224, 224), batch_size=32, class_mode='categorical')
         # VERIFICAMOS LAS CLASES ENCONTRADAS
         print("Clases encontradas en entrenamiento:", train_generator.class_indices)
         print("Número de imágenes de entrenamiento:", train_generator.samples)
         print("Número de imágenes de validación:", val_generator.samples)
        Found 1649 images belonging to 3 classes.
        Found 183 images belonging to 3 classes.
        Clases encontradas en entrenamiento: {'keyboard': 0, 'monitor': 1, 'mouse': 2}
        Número de imágenes de entrenamiento: 1649
        Número de imágenes de validación: 183
In [12]: # IMPORTAMOS EL MODELO ResNet50 PREENTRENADO EN ImageNet Y EXCLUIMOS LAS CAPAS SUPERIORES
         base_model = ResNet50(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
         # CONGELAMOS LAS CAPAS DEL MODELO BASE PARA CONSERVAR LOS PESOS PREENTRENADOS
         base_model.trainable = False
         # AGREGAMOS LAS NUEVAS CAPAS DE CLASIFICACION
         model = models.Sequential()
         model.add(base_model)
         model.add(layers.GlobalAveragePooling2D())
         model.add(layers.Dense(1024, activation='relu'))
         model.add(layers.Dropout(0.5))
         # DEFINIMOS LAS 3 CLASES (Mouse, Teclado, Monitor)
         model.add(layers.Dense(3, activation='softmax'))
         # COMPILAMOS EL MODELO
         model.compile(optimizer=Adam(learning_rate=0.001), loss='categorical_crossentropy', metrics=['accuracy'])
         # ENTRENAMOS EL MODELO
         history = model.fit(train_generator, epochs=10, validation_data=val_generator)
         # GRAFICAMOS LOS RESULTADOS DE ENTRENAMIENTO
         plt.figure(figsize=(10, 5))
         plt.plot(history.history['accuracy'], label='Precisión entrenamiento')
         plt.plot(history.history['val_accuracy'], label='Precisión validación')
         plt.xlabel('Época')
         plt.ylabel('Precisión')
         plt.legend(loc='lower right')
         plt.title('Precisión durante el entrenamiento')
         plt.show()
        Epoch 1/10
        c:\Users\aless\AppData\Local\Programs\Python\Python312\Lib\site-packages\keras\src\trainers\data_adapter.py:122: UserWarning: Your `PyDataset` class should call `super().__init__
        (**kwargs)` in its constructor. `**kwargs` can include `workers`, `use_multiprocessing`, `max_queue_size`. Do not pass these arguments to `fit()`, as they will be ignored.
         self._warn_if_super_not_called()
                               -- 103s 2s/step - accuracy: 0.4608 - loss: 1.2578 - val_accuracy: 0.3880 - val_loss: 1.1752
        52/52 -
        Epoch 2/10
                               --- 64s 1s/step - accuracy: 0.5665 - loss: 0.9579 - val_accuracy: 0.5847 - val_loss: 0.9063
        52/52 -
        Epoch 3/10
                                -- 179s 3s/step - accuracy: 0.6438 - loss: 0.8483 - val_accuracy: 0.5628 - val_loss: 0.9091
        52/52 -
        Epoch 4/10
                                - 50s 920ms/step - accuracy: 0.6222 - loss: 0.8551 - val_accuracy: 0.5574 - val_loss: 0.9419
        52/52 -
        Epoch 5/10
                                -- 58s 1s/step - accuracy: 0.6295 - loss: 0.8636 - val_accuracy: 0.6284 - val_loss: 0.8546
        52/52 -
        Epoch 6/10
                                 - 230s 4s/step - accuracy: 0.6453 - loss: 0.8188 - val_accuracy: 0.6940 - val_loss: 0.8145
        52/52 -
        Epoch 7/10
                                 - 47s 869ms/step - accuracy: 0.6558 - loss: 0.7991 - val_accuracy: 0.6776 - val_loss: 0.8134
        52/52 -
        Epoch 8/10
                                - 49s 912ms/step - accuracy: 0.6829 - loss: 0.7646 - val_accuracy: 0.6066 - val_loss: 0.8487
        52/52 -
        Epoch 9/10
                                -- 50s 916ms/step - accuracy: 0.6811 - loss: 0.7468 - val_accuracy: 0.6011 - val_loss: 0.8645
        52/52 -
        Epoch 10/10
        52/52 -
                                 - 235s 5s/step - accuracy: 0.6423 - loss: 0.8283 - val_accuracy: 0.6120 - val_loss: 0.8629
                                                  Precisión durante el entrenamiento
           0.70
           0.65
           0.60
           0.55
           0.50
           0.45
                                                                                                   Precisión entrenamiento
           0.40
                                                                                                   Precisión validación
                     0
                                          2
                                                                4
                                                                                      6
                                                                                                            8
                                                                    Época
In [13]: # DESCONGELAMOS ALGUNAS CAPAS DEL MODELO BASE
         base_model.trainable = True
         # DESCONGELAMOS LAS ULTIMAS 10 CAPAS
         for layer in base_model.layers[:-10]:
             layer.trainable = False
         # COMPILAMOS NUEVAMENTE EL MODELO CON UN learning_rate BAJO
         model.compile(optimizer=Adam(learning_rate=1e-5), loss='categorical_crossentropy', metrics=['accuracy'])
         # ENTRENAMOS NUEVAMENTE EL MODELO PARA AJUSTE FINO
         fine_tune_history = model.fit(train_generator, epochs=10, validation_data=val_generator)
         # GRAFICAMOS LOS RESULTADOS DEL ENTRENAMIENTO (entrenamiento + ajuste fino)
         plt.figure(figsize=(10, 5))
         plt.plot(history.history['accuracy'] + fine_tune_history.history['accuracy'], label='Precisión entrenamiento')
         plt.plot(history.history['val_accuracy'] + fine_tune_history.history['val_accuracy'], label='Precisión validación')
         plt.xlabel('Época')
         plt.ylabel('Precisión')
         plt.legend(loc='lower right')
         plt.title('Precisión durante el ajuste fino')
         plt.show()
        Epoch 1/10
                                 - 79s 1s/step - accuracy: 0.5573 - loss: 1.2134 - val_accuracy: 0.6066 - val_loss: 0.8443
        52/52 -
        Epoch 2/10
                                 - 71s 1s/step - accuracy: 0.6983 - loss: 0.7275 - val_accuracy: 0.4590 - val_loss: 1.1455
        52/52 -
        Epoch 3/10
                                  847s 17s/step - accuracy: 0.7303 - loss: 0.6615 - val_accuracy: 0.4317 - val_loss: 1.3065
        52/52 -
        Epoch 4/10
        52/52 -
                                 - 54s 1s/step - accuracy: 0.7281 - loss: 0.6692 - val_accuracy: 0.4590 - val_loss: 1.1417
        Epoch 5/10
                                  - 53s 980ms/step - accuracy: 0.7180 - loss: 0.6478 - val_accuracy: 0.5464 - val_loss: 0.9785
        52/52 -
        Epoch 6/10
                                  66s 1s/step - accuracy: 0.7423 - loss: 0.6126 - val_accuracy: 0.6885 - val_loss: 0.7259
        52/52 -
        Epoch 7/10
                                  - 83s 2s/step - accuracy: 0.7489 - loss: 0.6064 - val_accuracy: 0.6995 - val_loss: 0.7429
        52/52 -
        Epoch 8/10
                                 - 156s 3s/step - accuracy: 0.7537 - loss: 0.5812 - val_accuracy: 0.7104 - val_loss: 0.6918
        52/52 -
        Epoch 9/10
                                 - 53s 986ms/step - accuracy: 0.7609 - loss: 0.5869 - val_accuracy: 0.7541 - val_loss: 0.6530
        52/52 -
        Epoch 10/10
        52/52 -
                                  • 54s 986ms/step - accuracy: 0.7800 - loss: 0.5578 - val_accuracy: 0.7705 - val_loss: 0.6576
                                                    Precisión durante el ajuste fino
           0.80
           0.75
           0.70
           0.65
        Precisión
25'0
99'0
           0.50
           0.45
                                                                                                   Precisión entrenamiento
           0.40
                                                                                                   Precisión validación
                                2.5
                                              5.0
                                                          7.5
                    0.0
                                                                       10.0
                                                                                    12.5
                                                                                                15.0
                                                                                                             17.5
                                                                   Época
In [15]: # OBTENEMOS UN LOTE DE IMAGENES ALEATORIAS DE VALIDACION
         val_images, val_labels = next(val_generator)
         predictions = model.predict(val_images)
         # VISUALIZAMOS LAS IMAGENES CON SUS PREDICCIONES
         class_names = ['keyboard', 'monitor', 'mouse']
         plt.figure(figsize=(10,10))
         for i in range(9):
             plt.subplot(3, 3, i + 1)
             plt.imshow(val_images[i])
             plt.title(f"Verdadero: {class_names[np.argmax(val_labels[i])]} \nPredicción: {class_names[np.argmax(predictions[i])]}")
             plt.axis('off')
         plt.show()
                                1s 958ms/step
        1/1 -
           Verdadero: keyboard
                                                  Verdadero: monitor
                                                                                        Verdadero: monitor
            Predicción: keyboard
                                                   Predicción: mouse
                                                                                         Predicción: mouse
                                                                                         Verdadero: mouse
            Verdadero: keyboard
                                                   Verdadero: mouse
            Predicción: keyboard
                                                                                         Predicción: mouse
                                                   Predicción: mouse
           Verdadero: keyboard
                                                   Verdadero: mouse
                                                                                         Verdadero: mouse
            Predicción: keyboard
                                                   Predicción: mouse
                                                                                         Predicción: mouse
```